Machine Learning Testing

Pseudo paper

چکیده

آزمون سامانه‌های یادگیری ماشین با چالش‌هایی مواجه است که از ماهیت و ساختار اساساً متفاوت این سامانه‌ها در مقایسه با نرم‌افزارهای سنتی ـ که معمولاً قطعی‌تر و کمتر مبتنی بر روش‌های آماری هستند ـ ناشی می‌شود. برای مثال، یک سامانه یادگیری ماشین ذاتاً از الگوی برنامه نویسی داده‌محور پیروی می‌کند؛ به این معنا که منطق تصمیم‌گیری آن نه به‌صورت صریح توسط برنامه‌نویس، بلکه از طریق فرایند آموزش بر روی داده‌ها و در چارچوب معماری الگوریتم یادگیری ماشین استخراج می‌گردد. همین ویژگی باعث می‌شود آزمون سامانه‌های یادگیری ماشین دشوار باشد، زیرا این سامانه‌ها برای پاسخ گویی به مسائلی طراحی شده‌اند که پیش‌تر پاسخ مشخص یا از پیش تعریف شده‌ای برای آن‌ها وجود نداشته است.

مقدمه

استفاده گسترده از یادگیری ماشین در حوزه‌های مختلف، به طور طبیعی نگرانی‌هایی درباره‌ی قابل اعتماد بودن این سیستم ها ایجاد کرده است. کاربردها در حوزه‌های حساس به ایمنی، مانند خودروهای خودران و تشخیص‌های پزشکی، اهمیت اطمینان از صحت عملکرد، مقاومت در برابر خطا، حفظ حریم خصوصی، کارایی و عدالت را برجسته می‌کند. در این زمینه، تست نرم‌افزار(که به‌عنوان هر فعالیت سیستماتیک با هدف شناسایی تفاوت‌ها بین رفتار واقعی و رفتار مورد انتظار سیستم تعریف می‌شود) به عنوان یک روش حیاتی مطرح است. پیشرفت‌ها و افزایش علاقه به تست یادگیری ماشین نشان داده است که این روش در کشف آسیب‌پذیری‌های سیستم مؤثر بوده و می‌تواند قابلیت اعتماد و اطمینان‌پذیری سیستم‌های یادگیری ماشین را افزایش دهد.

مقدمات یادگیری ماشین

یادگیری ماشین (ML) شاخه‌ای از هوش مصنوعی است که به سیستم‌ها امکان می‌دهد بر اساس داده‌ها تصمیم‌گیری یا پیش‌بینی کنند. یک سیستم یادگیری ماشین معمولاً از چند مؤلفه‌ی کلیدی تشکیل شده است:

داده‌ها :(Dataset) مجموعه‌ای از نمونه‌ها که برای ساخت یا ارزیابی مدل یادگیری ماشین استفاده می‌شوند. به‌طور کلی، داده‌ها به دسته‌های زیر تقسیم می‌شوند:

- **داده‌های آموزشی :(Training data)** داده‌هایی که برای «آموزش» الگوریتم و انجام وظیفه‌ی موردنظر استفاده می‌شوند.
- **داده‌های اعتبارسنجی :(Validation data)** داده‌هایی که برای تنظیم و بهینه‌سازی ابرپارامترهای الگوریتم یادگیری به کار می‌روند.
- **داده‌های آزمایشی :(Test data)** داده‌هایی که برای سنجش و اعتبارسنجی رفتار مدل آموزش‌دیده استفاده می‌شوند.

برنامه‌ی یادگیری :(Learning program) کد نرم‌افزاری که توسط توسعه‌دهندگان برای ساخت، آموزش و ارزیابی سیستم یادگیری ماشین نوشته می‌شود.

چارچوب :(Framework) چارچوب به کتابخانه یا پلتفرمی گفته می‌شود که برای توسعه و پیاده‌سازی یک مدل یادگیری ماشین استفاده می‌شود. این چارچوب ابزارها، توابع آماده و ساختارهایی را فراهم می‌کند که فرآیند ساخت، آموزش و ارزیابی مدل را تسهیل می‌کنند (Pytorch , Tensor Flow , Scikit-learn , Keras , Caffe).

نمونه :(Instance) نمونه یک نقطه داده‌ای منفرد است که اطلاعات مربوط به یک شیء یا رویداد خاص را در یک مجموعه داده ثبت می‌کند.

ویژگی :(Feature) ویژگی یک خاصیت قابل اندازه‌گیری یا مشخصه‌ای از پدیده مورد مشاهده است که برای توصیف و تمایز نمونه‌ها در یک مجموعه داده استفاده می‌شود.

برچسب :(Label) برچسب نشان‌دهنده‌ی مقدار یا دسته‌ای است که به هر نمونه داده در یک مجموعه داده اختصاص داده می‌شود.

خطای آزمایش :(Test Error) خطای آزمایش میزان اختلاف بین شرایط واقعی و پیش‌بینی‌های انجام‌شده توسط مدل یادگیری ماشین بر روی داده‌های دیده‌نشده را اندازه‌گیری می‌کند.

خطای تعمیم :(Generalization Error) خطای تعمیم نشان‌دهنده‌ی اختلاف مورد انتظار بین شرایط واقعی و پیش‌بینی‌های مدل برای هر داده معتبر و دیده‌نشده است.

مدل :(Model) مدل یک ساختار یادگیری ماشین است که منطق تصمیم‌گیری یا پیش‌بینی را کدگذاری می‌کند و از داده‌های آموزشی، برنامه یادگیری و چارچوب مربوطه آموزش داده می‌شود.

انواع یادگیری ماشین:

- **یادگیری نظارت‌شده :(Supervised Learning)** نوعی یادگیری ماشین که با داده‌های دارای برچسب آموزش داده می‌شود و برچسب‌ها به‌عنوان اهداف یادگیری عمل می‌کنند. این رایج‌ترین نوع یادگیری ماشین است.
- **یادگیری بدون نظارت :(Unsupervised Learning)** روشی که از داده‌های بدون برچسب استفاده می‌کند و بر ساختار و الگوهای ذاتی داده‌ها تکیه دارد.
- **یادگیری تقویتی :(Reinforcement Learning)** نوعی یادگیری که داده‌ها به شکل توالی‌های اعمال، مشاهدات و پاداش‌ها هستند. یادگیرنده تلاش می‌کند تا اعمال بهینه را در محیطی خاص یاد بگیرد تا مجموع پاداش‌ها را بیشینه کند.

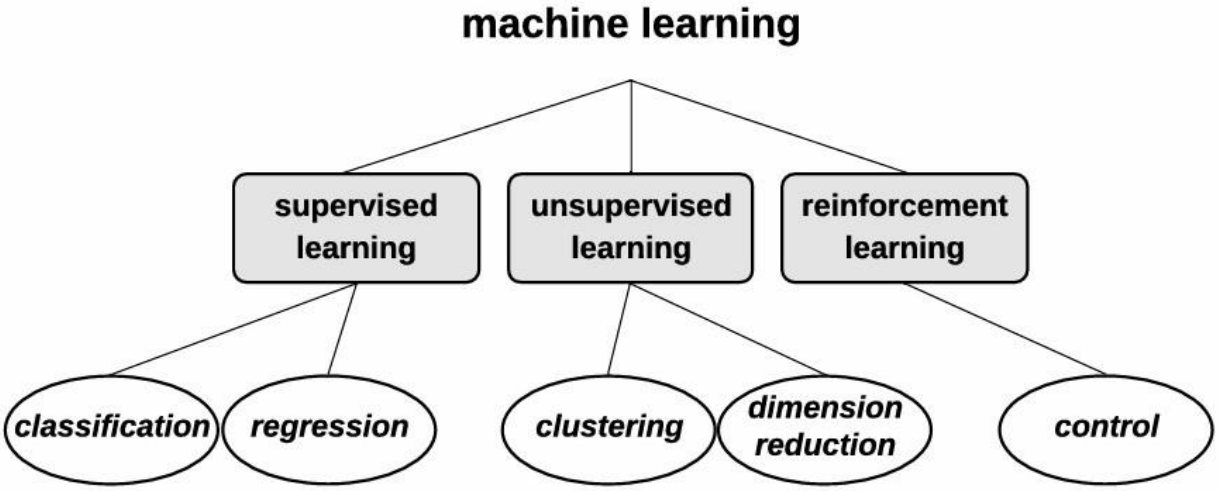


Figure 3: Machine learning categories and tasks

رابطه بین دسته‌های یادگیری ماشین و وظایف آن

وظایف یادگیری ماشین را می‌توان به دسته‌های مختلف یادگیری نسبت داد. در میان وظایف رایج، **طبقه‌بندی (Classification)** و **رگرسیون (Regression)** در حوزه‌ی یادگیری نظارت‌شده قرار می‌گیرند، در حالی که **خوشه‌بندی (Clustering)** و **کاهش ابعاد (Dimensionality Reduction)**معمولاً به یادگیری بدون نظارت تعلق دارند .

یادگیری تقویتی (Reinforcement Learning) عمدتاً برای تصمیم‌گیری در محیط‌های متوالی به کار می‌رود، مانند کنترل عامل‌های هوش مصنوعی در بازی‌ها برای به حداکثر رساندن پاداش‌های تجمعی.

علاوه بر این دسته‌بندی‌ها، یادگیری ماشین را می‌توان از منظر روش‌های الگوریتمی به **یادگیری ماشین کلاسیک** و **یادگیری عمیق (Deep Learning)** تقسیم کرد. الگوریتم‌هایی مانند **درخت تصمیم(Decision Tree)** ، **ماشین بردار پشتیبان(SVM)** ، **رگرسیون خطی (Linear Regression)**و **نایو بیز (Naive Bayes)** نمونه‌هایی از تکنیک‌های یادگیری ماشین کلاسیک هستند.

پس از معرفی مفاهیم پایه یادگیری ماشین، ضروری است بررسی شود که این ویژگی‌ها چه تأثیری بر فرایند آزمون دارند. از آنجا که رفتار سامانه‌های یادگیری ماشین برخلاف نرم‌افزارهای سنتی قطعی نیست و به داده وابستگی شدیدی دارد، روش‌های آزمون آن‌ها نیز نیازمند بازنگری اساسی هستند. بر همین اساس، در ادامه به تعریف و تحلیل آزمون یادگیری ماشین پرداخته می‌شود.

تست یادگیری ماشین(ML Testing)

این بخش به تعریف و تحلیل تست یادگیری ماشین می‌پردازد. در آن **گردش کار تست**)چگونگی تست(، **خواص تست** (چه چیزی باید تست شود) و **اجزای تست** (کجا باید تست شود) توضیح داده می‌شوند.

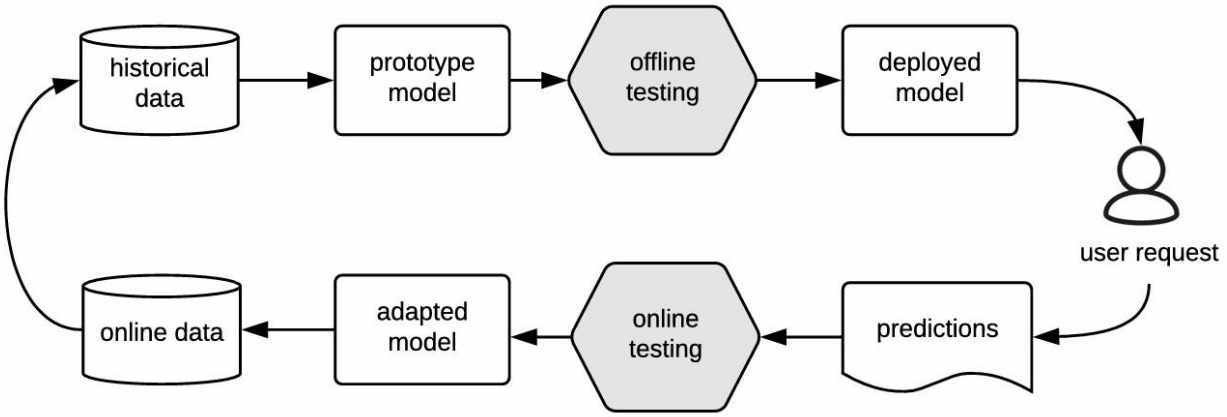
در نرم‌افزارهای سنتی، **باگ** به نقصی در برنامه گفته می‌شود که باعث ایجاد اختلاف بین رفتار واقعی و رفتار مورد انتظار می‌شود. در این زمینه، تعریف باگ به سیستم‌های یادگیری ماشین گسترش می‌یابد و هر گونه تفاوت بین رفتار واقعی و مورد انتظار سیستم یادگیری ماشین به عنوان باگ در نظر گرفته می‌شود.

تعریف 1 (باگ یادگیری ماشین) :باگ یادگیری ماشین به هر نقصی در یک مؤلفه یادگیری ماشین گفته می‌شود که باعث ایجاد اختلاف بین رفتار مشاهده شده و رفتار مورد انتظار می‌گردد.

تعریف 2 (تست یادگیری ماشین) :تست یادگیری ماشین به هر فعالیتی گفته می‌شود که با هدف کشف باگ‌های یادگیری ماشین طراحی شده باشد.

این تعاریف سه جنبه‌ی کلیدی سیستم‌های یادگیری ماشین را نشان می‌دهند :**شرایط مورد انتظار، مؤلفه‌های یادگیری ماشین** و **فعالیت‌های تست** .شرایط مورد انتظار می‌تواند شامل صحت عملکرد، مقاومت، حفظ حریم خصوصی، کارایی و عدالت باشد. باگ‌های یادگیری ماشین ممکن است در **داده‌ها، برنامه یادگیری** یا **چارچوب** وجود داشته باشند. فعالیت‌های تست ممکن است شامل تولید ورودی‌های تست، شناسایی اوراکل‌های تست، ارزیابی کفایت تست و اولویت‌بندی باگ‌های شناسایی شده باشد.

نقش تست در توسعه



چرخه حیات استقرار یک سیستم یادگیری ماشینی به همراه فعالیت‌های تست یادگیری ماشینی.

با مشخص شدن مفهوم آزمون در سیستم‌های یادگیری ماشین، گام بعدی بررسی نحوه اعمال این آزمون‌ها در چرخه حیات سیستم است. از آنجا که مدل‌ها هم پیش از استقرار و هم در زمان اجرا ممکن است دچار خطا شوند، آزمون به دو دسته اصلی آفلاین و آنلاین تقسیم می‌شود که هر یک نقش متفاوتی در تضمین کیفیت سیستم ایفا می‌کنند.

تست آفلاین و آنلاین در استقرار یادگیری ماشین

در مرحله‌ی ابتدایی استقرار، یک **مدل نمونه (prototype model)** با استفاده از داده‌های تاریخی ایجاد می‌شود. پیش از استقرار مدل در محیط عملیاتی، **تست آفلاین**، مانند اعتبارسنجی متقاطع(cross-validation) ، انجام می‌شود تا اطمینان حاصل شود که مدل شرایط مورد انتظار را برآورده می‌کند. تست آفلاین به توسعه‌دهندگان امکان می‌دهد رفتار مدل را در شرایط کنترل‌شده بررسی کنند و مشکلات احتمالی را قبل از مواجهه با داده‌های واقعی شناسایی نمایند. پس از استقرار، مدل پیش‌بینی‌هایی بر روی داده‌های زنده انجام می‌دهد که می‌توان آن‌ها را از طریق **تست آنلاین** تحلیل کرد تا نحوه تعامل مدل با رفتار واقعی کاربران ارزیابی شود.

تست آنلاین به دلایل زیر ضروری است:

1. **نمایندگی محدود داده‌های آفلاین :**تست آفلاین به داده‌های آزمایشی از پیش جمع‌آوری‌شده وابسته است که ممکن است توزیع داده‌های آینده یا دیده‌نشده را به‌طور کامل نشان ندهد.
2. **ناتوانی در شبیه‌سازی شرایط واقعی :**تست آفلاین نمی‌تواند تمامی سناریوهای عملی را که ممکن است مشکل ساز شوند، مانند از دست رفتن داده، تأخیر شبکه یا رفتار غیرمنتظره سیستم، پوشش دهد.
3. **دسترسی به معیارهای کسب‌وکار :**تست آفلاین دیدگاهی نسبت به معیارهای کلیدی کسب‌وکار، مانند نرخ باز شدن ایمیل، زمان مطالعه و نرخ کلیک ارائه نمی‌دهد، در حالی که این معیارها برای ارزیابی اثر واقعی مدل ضروری هستند.

تست آفلاین

تست آفلاین با **تحلیل نیازمندی‌ها** آغاز می‌شود، جایی که توسعه دهندگان انتظارات کاربران و مشخصات سیستم یادگیری ماشین را تعریف می‌کنند. این مرحله همچنین شامل برنامه‌ریزی کل فرآیند تست است.

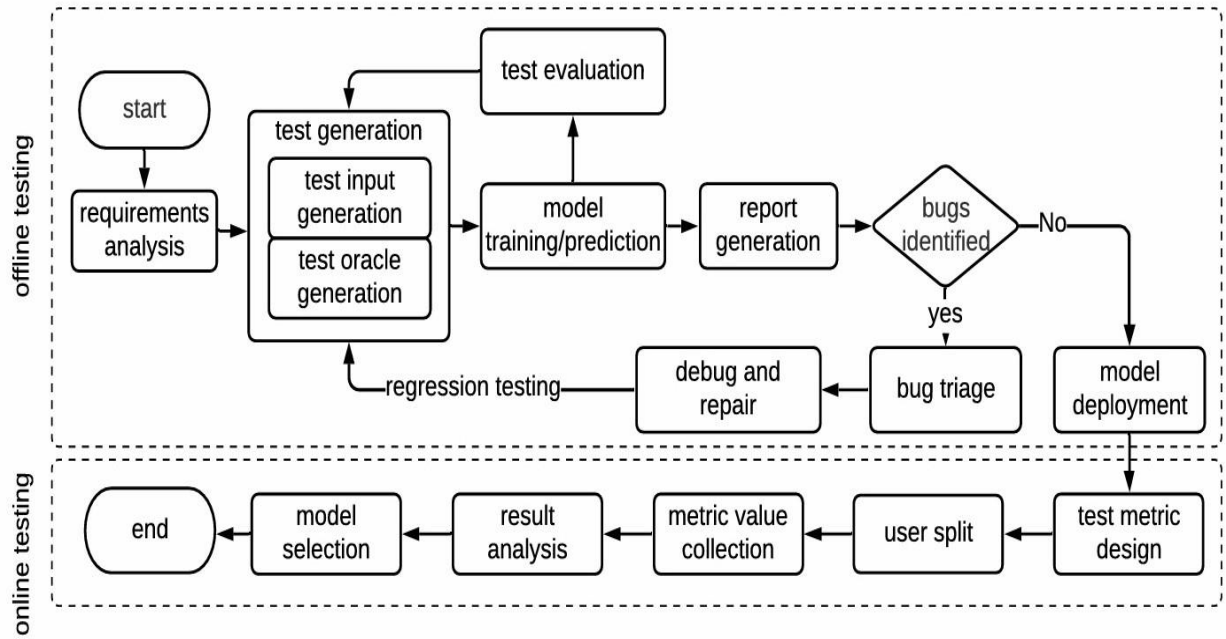
سپس **ورودی‌های تست** یا از داده‌های جمع‌آوری‌شده نمونه‌برداری می‌شوند یا برای اهداف خاص تولید می‌گردند، و **اوراکل‌های تست** برای تعیین نتایج مورد انتظار شناسایی یا ساخته می‌شوند. پس از آماده شدن تست‌ها، آن‌ها اجرا می‌شوند؛ یا با استفاده از داده‌های آموزشی برای ساخت مدل، یا با اجرای مدل آموزش‌دیده بر روی داده‌های آزمایشی. در طول اجرای تست، توسعه دهندگان بررسی می‌کنند که آیا اوراکل‌های تست نقض شده‌اند یا خیر.

پس از اجرا، **معیارهای ارزیابی** برای سنجش کیفیت تست‌ها به کار می‌روند، به‌ویژه توانایی آن‌ها در کشف مشکلات احتمالی ML و اطمینان از برآورده شدن نیازمندی‌های تعریف شده.

تست آنلاین

روش‌های تست آنلاین بسته به اهداف و زمینه‌های کاربرد متفاوت است .**نظارت در زمان اجرا (Runtime Monitoring)** به طور مداوم بررسی می‌کند که آیا سیستم یادگیری ماشین مستقر شده الزامات را رعایت می‌کند یا خصوصیات مورد انتظار زمان اجرا را نقض می‌کند. رویکرد رایج دیگر، **پایش پاسخ کاربران** است تا مشخص شود آیا مدل جدید نسبت به نسخه قبلی در شرایط کاربردی مشخص عملکرد بهتری دارد یا خیر.

با ترکیب تست آفلاین و آنلاین، توسعه دهندگان می‌توانند باگ‌های یادگیری ماشین را به‌صورت سیستماتیک شناسایی کنند، رفتار مدل را هم در محیط کنترل‌شده و هم در دنیای واقعی اعتبارسنجی کنند و عملکرد و قابلیت اعتماد سیستم را بهبود بخشند.

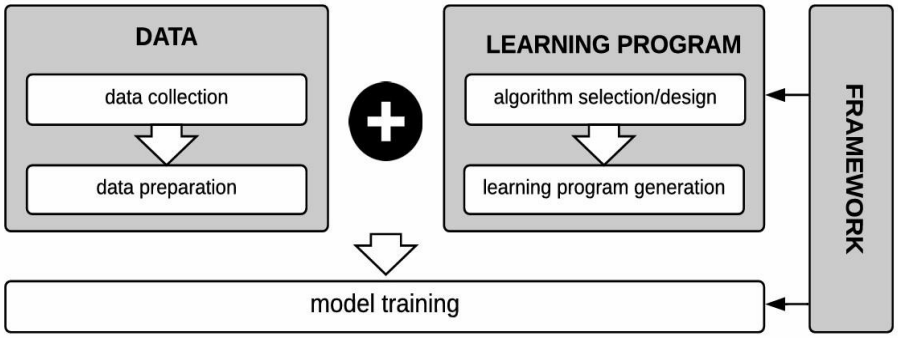


اگرچه آزمون آفلاین و آنلاین چارچوب کلی ارزیابی سیستم را مشخص می‌کنند، اما شناسایی باگ‌ها بدون بررسی اجزای سازنده سیستم امکان‌پذیر نیست. بنابراین، در ادامه تمرکز بر اجزای کلیدی سیستم یادگیری ماشین، یعنی داده و برنامه یادگیری، قرار می‌گیرد که بیشترین تأثیر را بر رفتار نهایی مدل دارند.

اجزای تست یادگیری ماشین(ML Testing Components)

ساخت یک مدل یادگیری ماشین شامل چندین جزء مرتبط با یکدیگر است. معمولاً یک توسعه‌دهنده نرم‌افزار ML باید داده‌ها را جمع‌آوری و برچسب‌گذاری کند، معماری برنامه یادگیری را طراحی کند و معماری پیشنهادی را با استفاده از چارچوب‌های مشخص پیاده‌سازی کند .هر یک از این اجزا(داده‌ها، برنامه یادگیری و چارچوب یادگیری)نقش حیاتی در فرآیند توسعه ایفا می‌کنند و ممکن است شامل باگ‌های یادگیری ماشین باشند که بر عملکرد کل سیستم تأثیر می‌گذارند.

بنابراین، تست یادگیری ماشین بر اعتبارسنجی سیستماتیک هر جزء متمرکز است تا نقص‌ها شناسایی شده و اطمینان حاصل شود که مدل رفتار مورد انتظار را ارائه می‌دهد. با تست هر جزء به‌صورت جداگانه و در ترکیب با دیگر اجزا، توسعه دهندگان می‌توانند مشکلات را به موقع شناسایی و رفع کرده و مقاومت، قابلیت اعتماد و اطمینان‌پذیری مدل را افزایش دهند.



کشف باگ در داده‌ها

رفتار و عملکرد یک سیستم یادگیری ماشین به شدت به کیفیت داده‌های آن وابسته است. باگ‌ها یا مشکلات موجود در داده‌ها می‌توانند عملکرد مدل را به‌طور قابل توجهی تحت تأثیر قرار دهند و با گذشت زمان تشدید شده و مشکلات جدی‌تری ایجاد کنند .کشف باگ در داده‌ها شامل شناسایی و رفع مشکلات احتمالی داده‌ای است که می‌توانند کارایی مدل را کاهش دهند. جنبه‌های کلیدی عبارتند از:

1. کامل بودن داده‌ها :اطمینان از اینکه مجموعه داده برای آموزش و آزمایش مدل کافی است.
2. نمایندگی داده‌ها :بررسی اینکه داده‌ها به‌طور دقیق توزیع داده‌های آینده یا داده‌های دیده‌نشده را منعکس می‌کنند.
3. نویز و تعصب :شناسایی و اصلاح داده‌های نویزی، مانند نمونه‌های دارای برچسب اشتباه یا تعصبی.
4. عدم تعادل داده‌ها :(Data Skew) بررسی ناسازگاری‌ها یا تفاوت توزیع بین داده‌های آموزشی و آزمایشی.
5. سم‌پاشی داده یا اطلاعات مخرب :شناسایی داده‌های مخرب یا مضر که می‌توانند عملکرد مدل را مختل کنند.

کشف سیستماتیک باگ‌های داده برای بهبود کیفیت، مقاومت و قابلیت اعتماد مدل در کاربردهای واقعی ضروری است.

خواص تست یادگیری ماشین(ML Testing Properties)

خواص تست نشان دهنده‌ی چه جنبه‌هایی از یک مدل یادگیری ماشین باید بررسی شود تا اطمینان حاصل گردد که مدل شرایط مورد نیاز را برآورده می‌کند. مهم ترین خواص تست عبارتند از:

1. درستی:(Correctness)
   درستی میزان احتمال این را می‌سنجد که سیستم یادگیری ماشین تحت آزمایش نتایج دقیق و مورد انتظار تولید کند. تضمین درستی، پایه‌ای برای اعتماد به پیش‌بینی‌های مدل است.
2. مرتبط بودن مدل:(Model Relevance)
   مدل یادگیری ماشین از ترکیب یک الگوریتم و داده‌های آموزشی حاصل می‌شود. مهم است که الگوریتم انتخاب شده بیش از حد پیچیده نباشد .مدل‌های بیش‌ازحد پیچیده ممکن است در تعمیم به داده‌های آینده موفق نباشند یا پیش‌بینی‌های نامطمئن داشته باشند.

3. امنیت:(Security)

امنیت به مقاومت سیستم یادگیری ماشین در برابر آسیب، دستکاری مخرب یا دسترسی غیرمجاز به اجزای آن اشاره دارد. امنیت ارتباط نزدیکی با مقاومت (robustness)دارد. سیستم‌هایی با مقاومت پایین، در برابر حملات مخرب آسیب‌پذیرتر هستند. برای مثال، اگر یک مدل نسبت به تغییرات داده‌های آموزشی یا ورودی حساس باشد، ممکن است در برابر سم‌پاشی داده یا حملات مخرب آسیب‌پذیر شود.

4. حریم خصوصی داده‌ها:(Data Privacy)

حریم خصوصی نشان‌دهنده توانایی سیستم یادگیری ماشین در حفاظت از اطلاعات حساس موجود در داده‌ها است. حفظ حریم خصوصی در کاربردهایی که داده‌های شخصی یا محرمانه دارند، حیاتی است.

5. کارایی:(Efficiency)

کارایی مربوط به سرعت و میزان استفاده از منابع سیستم یادگیری ماشین در مرحله آموزش یا پیش‌بینی است. مشکلات کارایی زمانی رخ می‌دهد که سیستم با کندی اجرا شود یا در زمان معقولی خاتمه نیابد. با توجه به رشد نمایی داده‌ها و پیچیدگی سیستم‌ها، کارایی اغلب معیار مهمی است و گاهی حتی از دقت نیز برای انتخاب مدل یا چارچوب مهم‌تر است.

6. عدالت:(Fairness)

سیستم‌های ML به طور گسترده در تصمیم‌گیری، مانند پیش‌بینی درآمد یا درمان پزشکی، استفاده می‌شوند. از آنجا که مدل‌های ML الگوها را از داده‌های آموزشی می‌آموزند، ممکن است به طور ناخواسته سوگیری‌های انسانی موجود در داده‌ها یا طراحی الگوریتم را یاد بگیرند. تضمین عدالت شامل شناسایی و کاهش این سوگیری‌ها برای جلوگیری از نتایج تبعیض‌آمیز یا غیراخلاقی است.

تست نرم‌افزار در مقابل تست یادگیری ماشین

تست نرم‌افزار سنتی و تست یادگیری ماشین (ML) در چندین جنبه‌ی اساسی با یکدیگر متفاوت هستند:

1. **جزء مورد تست:**
   تست نرم‌افزار سنتی عمدتاً بر شناسایی باگ‌ها در کد تمرکز دارد، در حالی که تست MLباگ‌ها را در داده‌ها، برنامه یادگیری و چارچوب شناسایی می‌کند که همه برای ساخت یک مدل ML حیاتی هستند.
2. **رفتار تحت تست:**
   رفتار کد نرم‌افزار سنتی معمولاً پس از مشخص شدن نیازمندی‌ها ثابت است، اما رفتار مدل ML می‌تواند با به‌روزرسانی داده‌های آموزشی یا تغییرات آن، به‌طور مکرر تغییر کند.
3. **ورودی تست:**
   در تست نرم‌افزار سنتی، ورودی‌های تست معمولاً همان داده‌های ورودی برای کد هستند. در تستML ، ورودی‌های تست می‌توانند اشکال متنوعی داشته باشند. تفاوت بین ورودی تست و داده تست مهم است:
   - ورودی تست :هر ورودی در هر شکل که برای انجام تست ML استفاده شود.
   - داده تست :به‌طور خاص به داده‌هایی گفته می‌شود که برای اعتبارسنجی رفتار مدل استفاده می‌شوند.

   بنابراین، ورودی‌های تست در ML می‌توانند شامل داده‌های تست، مجموعه‌های آموزشی کوچک، یا حتی برنامه یادگیری باشند. به عنوان مثال، هنگام تست برنامه یادگیری، ورودی تست می‌تواند یک نمونه تست یا مجموعه آموزشی کوچک باشد؛ هنگام تست کیفیت داده، ورودی تست می‌تواند برنامه یادگیری باشد.

4. **اوراکل تست:**

در تست نرم‌افزار سنتی معمولاً وجود یک اوراکل تست فرض می‌شود و خروجی‌ها با مقادیر مورد انتظار مقایسه می‌شوند. درML ، خروجی‌ها پس از استقرار تولید می‌شوند و صحت آن‌ها اغلب به‌صورت دستی تأیید می‌شود. شناسایی اوراکل تست در ML چالش‌برانگیز است، زیرا:

- بسیاری از خواص مورد نظر به سختی قابل مشخص کردن رسمی هستند.
- دانش تخصصی حوزه اغلب مورد نیاز است و فرآیند شناسایی اوراکل زمان‌بر و پرهزینه است.

برای کاهش این مشکل، شرکت‌ها ممکن است از خدمات برچسب‌گذاری داده‌های ثالث یا روابط متامورفیک (metamorphic relations) به‌عنوان شبه اوراکل استفاده کنند.

5. **معیارهای کفایت تست:**

نرم‌افزار سنتی از معیارهای کمی مانند پوشش خط، پوشش شاخه و پوشش جریان داده برای سنجش کفایت تست استفاده می‌کند. نرم‌افزار ML به معیارهای جدیدی نیاز دارد که ویژگی‌های منحصر به فرد پارادایم برنامه نویسی و نمایش منطق آن را در نظر بگیرند، زیرا معیارهای سنتی قادر به پوشش این ویژگی‌ها نیستند.

6. **مثبت کاذب در باگ‌های شناسایی‌شده:**

به دلیل دشواری در دسترسی به اوراکل‌های قابل اعتماد، تست ML معمولاً نسبت به تست نرم‌افزار سنتی مثبت کاذب بیشتری در گزارش باگ‌ها دارد.

7. **نقش تسترها:**

در تست نرم‌افزار سنتی، تسترها عمدتاً روی کد تمرکز می‌کنند. در تستML ، باگ‌ها ممکن است در داده، برنامه یادگیری یا الگوریتم وجود داشته باشند، بنابراین دانشمندان داده، طراحان الگوریتم یا مهندسان ML نیز می‌توانند نقش تستر را ایفا کنند.

نتیجه

آزمون سامانه‌های یادگیری ماشین، برخلاف آزمون نرم‌افزارهای سنتی، با چالش‌هایی نظیر رفتار غیرقطعی مدل‌ها، وابستگی شدید به داده و دشواری در تعریف اوراکل آزمون مواجه است. این تفاوت‌های ماهوی سبب می‌شود که روش‌های متعارف آزمون نرم‌افزار برای تضمین کیفیت و قابلیت اعتماد سامانه‌های یادگیری ماشین کافی نباشند.

این بررسی نشان می‌دهد که آزمون یادگیری ماشین تنها به ارزیابی درستی پیش‌بینی‌ها محدود نمی‌شود، بلکه ابعادی مانند پایداری، امنیت، حفظ حریم خصوصی، کارایی و عدالت را نیز در بر می‌گیرد. ازاین‌رو، آزمون باید به‌عنوان بخشی جدایی‌ناپذیر از چرخه توسعه و استقرار سامانه‌های یادگیری ماشین در نظر گرفته شود. پرداختن به چالش‌هایی مانند خودکارسازی اوراکل آزمون و مقابله با تغییر توزیع داده، نقش مهمی در توسعه سامانه‌های هوشمند قابل اعتماد در آینده خواهد داشت.

ساینا صفاری

ارشد نرم افزار کامپیوتر

درس تست نرم افزار